

Data quality

Цель


Выявить ошибки, аномальные и странные значения в признаках для их учёта при дальнейшем анализе.

Методология

1. Формирование временной карты данных, чтобы определить, присутствуют ли ошибки, связанные с temporal leakage.
2. Выявление и оценка дубликатов;
3. Анализ значений признаков по отдельности: ошибки, аномальные значения;
4. Совместный анализ значений признаков: согласованность значений между признаками;
5. Анализ пропусков;
6. Формирование выводов и ограничений.

Temporal leakage

Временная схема данных:



Скоринг выполняется в момент TOT_{0}. Признаки относятся к информации, доступной к этому моменту; временной горизонт для большинства из них явно не задан. Для num_30_59_days_late и num_60_89_days_late используется информация за 2 года до TOT_{0}. Целевая переменная (target) относится к будущему и отражает событие в течение следующих 2 лет после TOT_{0}.

Таким образом, явных признаков temporal leakage не обнаружено.

Duplicates

1. Датасет содержит **609** полных дубликатов с учётом target и **646** дубликатов без учёта target.
2. Выявленные дубликаты представляют собой совпадающие по значениям строки. Поскольку датасет не содержит уникальных идентификаторов заёмщиков, установить, являются ли они повторными записями одних и тех же клиентов, в рамках доступной документации невозможно.
3. Надёжно оценить отдельную связь дубликатов с target невозможно из-за ширины доверительного интервала bad rate. Кроме того, на бизнес-уровне совпадение набора признаков само по себе не позволяет считать запись нового заёмщика дубликатом.

Таким образом, совпадение строк по значениям само по себе не является достаточным основанием считать их ошибочными и удалять из выборки.

Features Values Quality

Признак	Ограничения	Соответствие ограничениям
Revolving Utilization	- признак не может принимать отрицательных значений; - значения существенно выше 1 требуют отдельной проверки; - положительные значения признака должны сопровождаться положительными значениями <code>num_open_credit_lines</code>.	- признак не содержит ошибок, связанных с отрицательными значениями; - распределение экстремальных значений плохо согласуется с буквальной интерпретацией признака как отношения; точную причину по имеющейся документации установить нельзя; - в рамках текущей документации сделать вывод о ситуации, когда <code>revolving_utilization</code> положителен, а <code>num_open_credit_lines</code> = 0, не представляется возможным.
Age	- признак не может принимать отрицательных значений; - признак не может принимать значения меньше 18 лет (возраст совершеннолетия); - высокие значения, порядка 90, являются подозрительными.	- признак не содержит ошибок, связанных с отрицательными значениями; - есть один представитель с возрастом 0 лет - это явно ошибка; - в рамках доступной документации нет достаточных оснований считать экстремальные возрастные значения ошибочными, поэтому они сохраняются без изменений.
Previous DPD	- признаки не могут принимать отрицательных значений; - признаки не могут принимать слишком большие значения (порядка 50, сотен и так далее).	- признаки не содержат ошибок, связанных с отрицательными значениями; - признаки не содержат ненормально больших значений, кроме 96 и 98; - значения 96 и 98 рассматриваются как незадокументированные системные коды.
Debt Ratio	- признак не может принимать отрицательных значений; - значения, превышающие 1, выглядят подозрительными.	- признак не содержит ошибок, связанных с отрицательными значениями; - экстремальные значения имеют распределение, несовместимое с буквальной интерпретацией показателя как обычного ratio. Возможными объяснениями являются особенности расчёта показателя при малом/нулевом знаменателе, изменение семантики поля или ошибки данных. Исходная документация не позволяет установить точную причину.
Monthly Income	- признак не может принимать отрицательных значений; - признак не должен принимать явно неправдоподобно большие значения, например порядка десятков и сотен миллионов.	- признак не содержит ошибок, связанных с отрицательными значениями; - признак не содержит ошибок, связанных с экстремальными значениями.
Number Open Credit Lines	- признак не может принимать отрицательных значений; - признак не должен принимать чрезмерно большие значения порядка сотен.	- признак не содержит ошибок, связанных с отрицательными значениями; - признак не содержит ошибок, связанных с экстремальными значениями.
Number Real Estate Loans	- признак не может принимать отрицательных значений; - признак не должен принимать чрезмерно большие значения порядка сотен.	- признак не содержит ошибок, связанных с отрицательными значениями; - признак не содержит ошибок, связанных с экстремальными значениями.
Number Dependents	- признак не может принимать отрицательных значений; - признак не должен принимать чрезмерно большие значения порядка сотен.	- признак не содержит ошибок, связанных с отрицательными значениями; - признак не содержит ошибок, связанных с экстремальными значениями.

Таким образом, несмотря на наличие некоторых особенностей (системные коды, возможная смена семантики признака, отдельные несогласованности), явных ошибок в данных, за исключением одного наблюдения с возрастом 0 лет, не обнаружено. Однако эти особенности необходимо учитывать при построении скоринговой модели.

Missing Values

Признак	Вывод
Monthly Income	1. Пропуски в Monthly Income связаны с экстремальными значениями Debt Ratio; 2. Наблюдения с отсутствующим Monthly Income по большинству характеристик несущественно отличаются от выборки в целом; 3. Выраженной связи между пропуском Monthly Income и target не наблюдается.
Number Dependents	1. Среднее количество кредитов примерно в 2 раза ниже, чем по датасету в целом; 2. по одному из признаков краткосрочной просрочки среднее значение примерно в 2 раза выше, чем по датасету в целом; 3. по другому признаку краткосрочной просрочки среднее значение примерно в 4 раза выше, чем по датасету в целом; 4. bad rate в среднем примерно на 25% ниже, чем по датасету в целом; 5. распределение наблюдений с пропущенным num_dependents отличается от распределения наблюдений с нулевым количеством иждивенцев.

Таким образом, в данных присутствует значительная доля пропусков, которую необходимо учитывать при построении скоринговой модели.

Выводы и ограничения

1. Явных признаков temporal leakage не обнаружено;
2. Наличие дубликатов как ошибочных повторных записей не подтверждено;
3. За одним исключением данные не содержат явных ошибок. Однако они имеют выраженные особенности, существенно влияющие на распределение значений признаков; это необходимо учитывать при построении базовой линейной скоринговой модели.
4. В целом данные согласованы; в рамках доступной документации оснований для обратного вывода нет.
5. Данные содержат пропуски, объём которых не позволяет просто удалить соответствующие наблюдения. Пропуски потребуют отдельной обработки при построении скоринговых моделей.