


Data quality

Temporal leakage

Временная схема данных:



Скоринг выполняется в момент T_0 . Признаки относятся к информации, доступной к этому моменту; временной горизонт для большинства из них явно не задан. Для `num_30_59_days_late` и `num_60_89_days_late` используется информация за 2 года до T_0 . Целевая переменная (`target`) относится к будущему и отражает событие в течение следующих 2 лет после T_0 .

Таким образом, явных признаков temporal leakage не обнаружено.

Duplicates

1. Датасет содержит 609 полных дубликатов с учётом `target` и 646 дубликатов без учёта `target`.
2. Выявленные дубликаты представляют собой совпадающие по значениям строки. Поскольку датасет не содержит уникальных идентификаторов заёмщиков, установить, являются ли они повторными записями одних и тех же клиентов, в рамках доступной документации невозможно.
3. Надёжно оценить отдельную связь дубликатов с `target` невозможно из-за ширины доверительного интервала `bad rate`. Кроме того, на бизнес-уровне совпадение набора признаков само по себе не позволяет считать запись нового заёмщика дубликатом.
4. Таким образом, совпадение строк по значениям само по себе не является достаточным основанием считать их ошибочными и удалять из выборки.

Features Values Quality

Признак	Ограничения	Соответствие ограничениям
Revolving Utilization	1. признак не может принимать отрицательных значений; 2. значения существенно выше 1 требуют отдельной проверки; 3. положительные значения признака должны сопровождаться положительными значениями num_open_credit_lines.	1. признак не содержит ошибок, связанных с отрицательными значениями; 2. распределение экстремальных значений плохо согласуется с буквальной интерпретацией признака как отношения; точную причину по имеющейся документации установить нельзя; 3. в рамках текущей документации сделать вывод о ситуации, когда revolving_utilization положителен, а num_open_credit_lines = 0, не представляется возможным.
Age	1. признак не может принимать отрицательных значений; 2. признак не может принимать значения меньше 18 лет (возраст совершеннолетия); 3. признак не должен принимать значения сильно выше 90.	1. признак не содержит ошибок, связанных с отрицательными значениями; 2. есть один представитель с возрастом 0 лет - это явно ошибка; 3. в рамках доступной документации нет достаточных оснований считать экстремальные возрастные значения ошибочными, поэтому они сохраняются без изменений.
Previous DPD	1. признаки не могут принимать отрицательных значений; 2. признаки не могут принимать слишком большие значения (порядка 50, сотен и так далее).	1. признаки не содержат ошибок, связанных с отрицательными значениями; 2. признаки не содержат ненормально больших значений, кроме 96 и 98; 3. значения 96 и 98 рассматриваются как незадокументированные системные коды.
Debt Ratio	1. признак не может принимать отрицательных значений; 2. признак не должен принимать значения сильно выше 1.	1. признак не содержит ошибок, связанных с отрицательными значениями; 2. экстремальные значения имеют распределение, несовместимое с буквальной интерпретацией показателя как обычного ratio. Возможными объяснениями являются особенности расчёта показателя при малом/нулевом знаменателе, изменение семантики поля или ошибки данных. Исходная документация не позволяет установить точную причину.
Monthly Income	1. признак не может принимать отрицательных значений; 2. признак не должен принимать явно неправдоподобно большие значения, например порядка десятков и сотен миллионов.	1. признак не содержит ошибок, связанных с отрицательными значениями; 2. признак не содержит ошибок, связанных с экстремальными значениями.
Number Open Credit Lines	1. признак не может принимать отрицательных значений; 2. признак не должен принимать чрезмерно большие значения порядка сотен.	1. признак не содержит ошибок, связанных с отрицательными значениями; 2. признак не содержит ошибок, связанных с экстремальными значениями.
Number Real Estate Loans	1. признак не может принимать отрицательных значений; 2. признак не должен принимать чрезмерно большие значения порядка сотен.	1. признак не содержит ошибок, связанных с отрицательными значениями; 2. признак не содержит ошибок, связанных с экстремальными значениями.
Number Dependents	1. признак не может принимать отрицательных значений; 2. признак не должен принимать чрезмерно большие значения порядка сотен.	1. признак не содержит ошибок, связанных с отрицательными значениями; 2. признак не содержит ошибок, связанных с экстремальными значениями.

Missing Values

Признак	Вывод
Monthly Income	1. Пропуски в Monthly Income связаны с экстремальными значениями Debt Ratio; 2. Наблюдения с отсутствующим Monthly Income по большинству характеристик несущественно отличаются от выборки в целом; 3. Выраженной связи между пропуском Monthly Income и target не наблюдается.
Number Dependents	1. Среднее количество кредитов примерно в 2 раза ниже, чем по датасету в целом; 2. по одному из признаков краткосрочной просрочки среднее значение примерно в 2 раза выше, чем по датасету в целом; 3. по другому признаку краткосрочной просрочки среднее значение примерно в 4 раза выше, чем по датасету в целом; 4. bad rate в среднем примерно на 25% ниже, чем по датасету в целом; 5. распределение наблюдений с пропущенным num_dependents отличается от распределения наблюдений с нулевым количеством иждивенцев.