

Risk analysis

Цель

Исследовать структуру кредитного риска портфеля и определить характеристики заёмщиков, связанные с повышенной вероятностью серьёзной просрочки в следующие два года.

Чтобы достичь поставленной цели, необходимо ответить на следующие бизнес-вопросы:

1. Какие характеристики сильнее всего связаны с bad rate?
2. Какие рискованные сегменты достаточно велики, чтобы существенно влиять на качество всего портфеля?
3. Какие характеристики дают выраженный risk gradient?
4. Какие сочетания характеристик особенно рискованы?

Методология

Анализ каждого признака по отдельности:

1. Сформировать предварительное разбиение признака на сегменты;
2. На основе предварительно сформированных сегментов построить график, отражающий их bad rate;
3. Опираясь на график и бизнес-значения сегментов, построить окончательные сегменты;
4. Для сформированных сегментов составить отчёт по **ключевым метрикам**;
5. По вычисленным сегментам составить итоговый график, отражающий сегменты и их bad rate;
6. Провести χ^2 -тест и рассчитать коэффициент Cramer's V для оценки зависимости между сегментами признака и target;
7. На основе полученного отчёта и графика сделать итоговый вывод по признаку;

Результатом анализа станет итоговая таблица, отражающая выявленные значимые связи между отдельными признаками и серьёзной будущей просрочкой.

Pairwise-анализ признаков:

1. Провести попарное пересечение сформированных сегментов признаков;
2. Для вычисленных пересечений составить отчёт по **ключевым метрикам**;
3. Выявить наиболее информативные пересечения, дающие значимый прирост Bad Share, BR и Lift при умеренном сокращении размера сегмента относительно исходных сегментов.

Результатом анализа станет итоговая таблица, отражающая наиболее значимые пересечения сегментов признаков при их наличии.

По итогам двух этапов анализа необходимо ответить на поставленные бизнес-вопросы.

Risk Factor Analysis

Feature	Cramer's V	Main pattern	Main risk segments	Dataset share	Bad Share	BR	Lift	Dataset relevance
Revolving Utilization	0.303	Сильная нелинейная градация уровня риска между сегментами.	(0.7, 1.0 (1.0, 2.0]	17.75 1.97	47.05 11.80	17.72 40.10	2.65 5.99	Very High
30-59 DPD	0.278	Bad rate заметно возрастает при наличии предыдущих просрочек.	[1, 2] (2, 13]	13.75 2.05	36.19 12.07	17.59 39.26	2.63 5.87	Very High
90+ DPD	0.350	Bad rate заметно возрастает при наличии предыдущих просрочек; между сегментами наблюдается выраженный risk gradient.	[1, 2] (2, 17]	4.53 0.85	25.34 7.82	37.38 61.68	5.59 9.23	High
60-89 DPD	0.282	Bad rate заметно возрастает при наличии предыдущих просрочек; между сегментами наблюдается выраженный risk gradient.	[1, 2] (2, 11]	4.57 0.32	23.32 2.84	34.14 58.64	5.11 8.77	High
Age	0.113	Для сегментов молодых заёмщиков (22–45) лет средний lift составляет около 1,57.	(22.0, 30.0 (30.0, 45.0]	6.67 23.03	11.92 37.65	11.79 9.31	1.76 1.39	Very Normal
Debt Ratio	0.062	В сегментах с высоким Debt Ratio — (0.7, 4.0] — наблюдается повышенный bad rate.	(0.7, 1.0 (1.0, 4.0]	4.89 3.50	8.17 6.36	11.15 12.16	1.67 1.82	Very Normal
Income	0.073	Для сегментов с низким и средним доходом — (900, 4500] — средний lift составляет около 1,39.	(900.0, 3000.0 (3000.0, 4500.0]	13.92 15.17	20.73 19.58	9.95 8.63	1.49 1.29	Normal
Real Estate Loans	0.062	Слабая нелинейная связь.	0	37.46	46.6	8.31	1.24	Normal

Feature	Cramer's V	Main pattern	Main risk segments	Dataset share	Bad Share	BR	Lift	Dataset relevance
Open Credit Lines	0.099	Высокий bad rate наблюдается у заёмщиков без открытых кредитных линий на момент скоринга.	0	1.26	4.83	25.64	3.84	Low
Dependents	0.047	Слабая нелинейная связь.	(2, 20]	8.89	12.30	9.25	1.38	Low

Cross-Segment Risk

Features	Segments	Size	Dataset Share	Bad Share	Bad Rate	Delta Bad Rate	Lift	Explanations
revolving_utilizationnum_60_89_days_late	(1.0, 2.0][1, 2]	757	0.005047	0.042789	0.566711	0.165694	8.478616	Очень высокий BR + выраженное дополнительное повышение
num_30_59_days_latenum_90_days_late	(2, 13][1, 2]	799	0.005327	0.043786	0.549437	0.156835	8.220179	Очень высокий BR + выраженное дополнительное повышение
num_30_59_days_latenum_60_89_days_late	(2, 13][1, 2]	987	0.006580	0.049970	0.507599	0.114997	7.594237	Очень высокий BR + выраженное дополнительное повышение
num_60_89_days_latenum_90_days_late	[1, 2][1, 2]	1731	0.011540	0.086575	0.501444	0.127658	7.502158	Очень высокий BR + выраженное дополнительное повышение + заметный объём
revolving_utilizationnum_30_59_days_late	(1.0, 2.0][1, 2]	1218	0.008120	0.056852	0.467980	0.066963	7.001501	Очень высокий BR + дополнительное повышение
agenum_30_59_days_late	(30.0, 45.0][2, 13]	979	0.006527	0.043387	0.444331	0.051729	6.647680	Очень высокий BR + дополнительное повышение
revolving_utilizationnum_30_59_days_late	(0.7, 1.0][2, 13]	1309	0.008727	0.057650	0.441558	0.048956	6.606201	Очень высокий BR + дополнительное повышение
num_30_59_days_latenum_90_days_late	[1, 2][1, 2]	2516	0.016773	0.105426	0.420111	0.046325	6.285327	Очень высокий BR + дополнительное повышение + заметный объём
revolving_utilizationnum_30_59_days_late	(0.7, 1.0][1, 2]	6184	0.041227	0.170058	0.275712	0.098561	4.124948	Выраженное повышение BR + очень значительный Bad Share
num_30_59_days_latenum_real_estate_loans	[1, 2]0	7437	0.049580	0.164871	0.222267	0.046415	3.325360	Высокий Bad Rate + очень значительный Bad Share
revolving_utilizationnum_60_89_days_late	(0.7, 1.0][1, 2]	2805	0.018700	0.117195	0.418895	0.077531	6.267128	Очень высокий BR + выраженное повышение BR + заметный объём
num_30_59_days_latenum_open_credit_lines	[1, 2][1, 2]	1369	0.009127	0.038300	0.280497	0.104645	4.196540	Высокий Bad Rate + выраженное дополнительное повышение
num_30_59_days_latenum_monthly_income	[1, 2](900.0, 3000.0]	3242	0.021613	0.074905	0.231647	0.055795	3.465696	Высокий Bad Rate + значительное дополнительное повышение + заметный объём
num_90_days_latenum_dependencies	[1, 2](2, 20]	788	0.005253	0.033513	0.426396	0.052610	6.379353	Очень высокий BR + значительное дополнительное повышение
revolving_utilizationdebt_ratio	(0.7, 1.0](1.0, 4.0]	1178	0.007853	0.026930	0.229202	0.052051	3.429115	Высокий Bad Rate + значительное дополнительное повышение

Key Findings

1. Какие характеристики сильнее всего связаны с bad rate? Наибольшую связь с риском имеют признаки:

1. **Revolving Utilization.** Ключевые риск-сегменты формируют около 59% всех bad events и одновременно характеризуются высоким bad rate;
2. **30-59 DPD, 60-89 DPD, 90+ DPD.** Ключевые риск-сегменты этих признаков концентрируют значительную долю всех bad events — примерно 26–48% — и характеризуются одними из самых высоких bad rate среди рассматриваемых признаков.

У остальных характеристик также встречаются сегменты с повышенным BR, однако их совокупная значимость для портфеля ниже из-за менее выраженного bad rate и/или меньших dataset share и bad share.

2. Какие рискованные сегменты достаточно велики, чтобы существенно влиять на качество всего портфеля? К таким сегментам относятся:

1. Высокий и экстремальный **Revolving Utilization** — (0.7, 2.0]. Эти сегменты формируют около 59% всех bad events и имеют bad rate не ниже ~17%, поэтому существенно влияют на качество портфеля;
2. Положительные **30-59 DPD, 60-89 DPD, 90+ DPD.** Несмотря на сравнительно небольшую долю выборки, соответствующие сегменты формируют примерно 26–48% всех bad events при dataset share порядка 5–15%, что указывает на их существенное влияние на качество портфеля;
3. Сегменты молодого и среднего **возраста** — (22.0, 45.0] — формируют около 49% всех bad events при доле в выборке около 26%, поэтому также заметно влияют на структуру риска.
4. Сегменты низкого и среднего **ежемесячного дохода** — (900.0, 4500.0] — формируют около 40% всех bad events при dataset share около 29%, поэтому также заметно влияют на структуру риска.

Остальные сегменты характеризуются либо меньшей концентрацией bad events, либо менее выраженным bad rate.

3. Какие характеристики дают выраженный risk gradient? Наиболее выраженный risk gradient наблюдается у следующих характеристик:

1. **Revolving utilization** - максимальный разброс ~38.1% между сегментами;
2. **30-59 DPD** - максимальный разброс ~35.2% между сегментами;
3. **60-89 DPD** - максимальный разброс ~53.5% между сегментами;
4. **90+ DPD** - максимальный разброс ~57.0% между сегментами.

У остальных признаков различия bad rate между сегментами выражены заметно слабее.

4. Какие сочетания характеристик особенно рискованы? Наиболее рискованными являются следующие сочетания характеристик:

1. Экстремальные значения **Revolving Utilization** ((1.0, 2.0]) в сочетании с **наличием просрочек**. Для таких комбинаций средний BR составляет порядка 43,4%;
2. **Одновременное наличие просрочек двух DPD-категорий**. Для таких сочетаний средний BR составляет порядка 49,5%;
3. Сочетание **коротких просрочек и среднего возраста** — (30.0, 45.0] — также характеризуется высоким BR, порядка 44%.

Для остальных рассмотренных сочетаний уровень риска заметно ниже, чем у перечисленных выше.

Limitations

Результаты анализа следует интерпретировать с учётом следующих ограничений исходных данных и выбранной методологии.

1. **Отсутствует временная структура данных.** Датасет не содержит даты формирования выборки, выдачи кредита и последовательной истории платежей по месяцам. Поэтому невозможно оценить изменение качества портфеля во времени, выполнить vintage analysis, roll-rate / migration analysis и проверить устойчивость обнаруженных закономерностей на out-of-time выборке.
2. **Отсутствуют данные для оценки экономического эффекта риска.** В выборке отсутствуют размер кредита / экспозиции, EAD, LGD, процентная ставка, доходность клиента и величина фактических кредитных потерь. Поэтому результаты позволяют анализировать частоту серьёзной просрочки и концентрацию bad events, но не позволяют оценивать ожидаемые денежные потери, прибыльность сегментов или экономически оптимальный credit cutoff.
3. **Target отражает серьёзную просрочку, а не полноценное определение дефолта.** Целевая переменная отражает наличие просрочки 90+ дней или более серьёзного нарушения платёжной дисциплины в течение следующих двух лет. Поэтому в рамках анализа `bad event` используется как индикатор кредитного риска, но его не следует напрямую отождествлять с регуляторным или внутренним банковским определением default.
4. **Часть значений имеет неизвестную бизнес-интерпретацию.** Значения `96` и `98` в DPD-признаках синхронно встречаются сразу в нескольких полях и рассматриваются как незадокументированные специальные системные коды. Исходная документация не раскрывает их точного значения, поэтому более конкретная интерпретация таких наблюдений была бы предположительной.
5. **Обнаруженные зависимости являются ассоциативными, а не причинными.** Повышенный bad rate внутри определённого возрастного, доходного, долгового или иного сегмента не означает, что соответствующая характеристика является причиной

будущей просрочки. Наблюдаемая связь может частично объясняться другими коррелирующими характеристиками заёмщиков.

6. **Границы части аналитических сегментов выбраны с использованием наблюдаемого bad-rate profile.** Для непрерывных признаков предварительные fine bins использовались для изучения формы зависимости с target, после чего соседние группы объединялись в более крупные и интерпретируемые сегменты. Поэтому различия между такими сегментами следует рассматривать как закономерности, обнаруженные в данной выборке, а не как независимо подтверждённые универсальные risk cutoffs.
7. **Pairwise-анализ включает перебор большого количества сочетаний сегментов.** При переборе большого числа пересечений возрастает вероятность выделить комбинации с высоким bad rate частично из-за случайных особенностей конкретной выборки. Для снижения этого эффекта использовались ограничения на минимальный размер сегмента и долю bad events, однако наиболее перспективные комбинации желательно дополнительно проверять на независимой validation или out-of-time выборке.
8. **Набор доступных признаков ограничен.** Датасет содержит только небольшое количество агрегированных характеристик клиента и не включает детальную кредитную историю, типы кредитных продуктов, даты и суммы платежей, запросы в кредитное бюро, региональные и другие потенциально значимые факторы. Поэтому проведённый анализ не отражает всей структуры риска, которая была бы доступна в реальном банковском портфеле.

Таким образом, полученные результаты следует рассматривать как **аналитическое исследование структуры кредитного риска внутри доступной выборки**. Они позволяют выявить risk gradients, концентрацию bad events и потенциально значимые сочетания характеристик, но не представляют собой готовую кредитную политику и не подтверждают устойчивость обнаруженных зависимостей на будущих портфелях.