

Scoring

Цель

Построить модель для оценки риска будущей серьезной просрочки заёмщиков и оценить её качество.

Методология

1. Формирование единого разбиения данных на обучающую и тестовую выборки.
2. Выбор представления данных (без преобразований или с дискретизацией признаков) для базовой и продвинутой моделей.
3. Построение базовой модели - логистическая регрессия:
 1. Подбор оптимальных гиперпараметров;
 2. Обучение с оптимальными гиперпараметрами;
 3. Оценка качества модели по ключевым метрикам (ROC-AUC, Gini, KS и PR-AUC) на отложенной части датасета.
4. Построение продвинутой модели - градиентного бустинга на решающих деревьях:
 1. Подбор оптимальных гиперпараметров;
 2. Обучение с оптимальными гиперпараметрами;
 3. Оценка качества модели по ключевым метрикам (ROC-AUC, Gini, KS и PR-AUC) на отложенной части датасета.
5. Выбор оптимальной модели на основе рассчитанных метрик качества.
6. Интерпретация модели логистической регрессии с целью оценки её согласованности с проведённым ранее risk-анализом.
7. Расчёт скоринговых оценок заёмщиков.
8. Формирование вывода.

Выбор типа датасета для моделей

Базовая модель: Для базовой модели целесообразно сравнить исходный датасет и датасет с дискретизированными признаками, поскольку многие признаки имеют нелинейную связь с риском будущей серьезной просрочки.

Продвинутая модель - CatBoost Classifier: CatBoost Classifier представляет собой градиентный бустинг на решающих деревьях. Разбиения в деревьях позволяют модели самостоятельно учитывать нелинейные зависимости и пороговые эффекты, поэтому предварительная дискретизация признаков для CatBoost не требуется; целесообразно использовать исходный датасет.

Сравнение качества датасетов на базовой модели:

Dataset Type	ROC-AUC	Gini	KS	PR-AUC
Base	0.8088	0.6176	0.4651	0.3384
Transformed	0.8513	0.7202	0.5461	0.3754
Delta	0.0430	0.0850	0.0810	0.0370


На validation sample Logistic Regression на дискретизированных признаках показывает более высокое качество по всем рассматриваемым ranking metrics. ROC-AUC увеличивается примерно на 0.043, что подтверждает полезность выбранного преобразования признаков для линейной модели.

Таким образом:

1. Для Logistic Regression будет использоваться датасет с дискретизированными признаками;
2. Для CatBoost будет использоваться исходный датасет.

Сравнение скоринговых моделей

Model	ROC-AUC	Gini	KS	PR-AUC
Logistic Regression	0.8597	0.7193	0.5687	0.3810
CatBoost Classifier	0.8724	0.7448	0.5922	0.4096
Delta PP	1.27	2.55	2.35	2.86



Таким образом: Logistic Regression:


1. Высокая интерпретируемость.
2. Низкая вычислительная сложность.
3. Хорошее качество risk ranking, умеренно уступающее CatBoost по рассматриваемым метрикам.

CatBoost Classifier:

1. Более низкая интерпретируемость.
2. Более высокая вычислительная сложность, которая для текущего объема данных не является существенным ограничением.
3. Более высокое качество по всем рассматриваемым ranking metrics на final holdout.

Для последующего ранжирования портфеля выбран CatBoost, поскольку на final holdout он показывает более высокое качество дискриминации по всем рассматриваемым метрикам. Logistic Regression при этом сохраняется как интерпретируемый baseline для сопоставления и анализа основных risk drivers.

Интерпретация модели логистической регрессии




Для интерпретации направления эффектов: При прочих равных положительные коэффициенты Logistic Regression связаны с более высоким predicted risk, а отрицательные — с более низким predicted risk. Величина коэффициента отражает изменение log-odds положительного класса и не должна интерпретироваться как прямое изменение вероятности серьезной просрочки или как причинный эффект признака.

Направления крупнейших коэффициентов в целом согласуются с risk patterns, выявленными в предыдущем анализе:

1. Сегменты с **высоким revolving_utilization** и наличием **previous DPD** имеют крупные положительные коэффициенты и связаны с повышенным predicted risk.
2. Сегменты **молодого и среднего возраста**, а также **высокого и экстремального debt_ratio** также характеризуются положительными коэффициентами и связаны с повышенным predicted risk.
3. Сегменты с **отсутствием previous DPD** и **низким revolving_utilization** имеют крупные отрицательные коэффициенты и связаны с пониженным predicted risk.
4. Для остальных сегментов абсолютные значения коэффициентов преимущественно ниже, поэтому их вклад в linear predictor выражен слабее.

Направления крупнейших коэффициентов Logistic Regression в целом согласуются с risk patterns, выявленными в предыдущем анализе. Это служит дополнительным sanity check содержательной согласованности модели, но не является доказательством причинной связи между признаками и риском серьёзной просрочки.

Проверка risk ranking: predicted risk vs observed bad rate



Observed bad rate монотонно возрастает от низких risk deciles к высоким: с 0,33% в D1 до 37,13% в D10. Это подтверждает, что на final holdout модель эффективно ранжирует заёмщиков по уровню относительного риска. При этом predicted risk scores систематически превышают observed bad rate, поэтому выход модели следует интерпретировать как risk score для ранжирования, а не как откалиброванную probability of default.

Вывод

1. Для базовой модели датасет с дискретизированными признаками даёт заметный прирост качества по ключевым метрикам, поэтому целесообразно использовать именно его;
2. С учётом качества по ключевым метрикам и применимости при заданных ограничениях продвинутая модель превосходит базовую, поэтому её целесообразно выбрать в качестве основной скоринговой модели;
3. Интерпретация коэффициентов базовой модели показала их согласованность с результатами проведённого ранее risk-анализа;
4. По мере роста predicted risk наблюдается монотонный рост observed bad rate, что подтверждает способность модели корректно ранжировать заёмщиков по уровню риска.