

# Scoring

## Выбор типа датасета для моделей

### Базовая модель:

Для базовой модели целесообразно сравнить исходный датасет и датасет с дискретизированными признаками, поскольку многие признаки имеют нелинейную связь с риском будущей серьёзной просрочки.

### Продвинутая модель - CatBoost Classifier:

CatBoost Classifier представляет собой градиентный бустинг над решающими деревьями. Разбиения в деревьях позволяют модели самостоятельно учитывать нелинейные зависимости и пороговые эффекты, поэтому предварительная дискретизация признаков для CatBoost не требуется и логично использовать исходный датасет.

### Сравнение качества датасетов на базовой модели:

| Dataset Type | ROC-AUC | Gini   | KS     | PR-AUC |
|--------------|---------|--------|--------|--------|
| Base         | 0.8088  | 0.6176 | 0.4651 | 0.3384 |
| Transformed  | 0.8513  | 0.7202 | 0.5461 | 0.3754 |
| Delta        | 0.0430  | 0.0850 | 0.0810 | 0.0370 |


На validation sample Logistic Regression на дискретизированных признаках показывает более высокое качество по всем рассматриваемым ranking metrics. ROC-AUC увеличивается примерно на 0,043, что подтверждает полезность выбранного преобразования признаков для линейной модели.

### Таким образом:

- 1. Для Logistic Regression будет использоваться датасет с дискретизированными признаками;
- 2. Для CatBoost будет использоваться исходный датасет.

## Сравнение скоринговых моделей

| Model               | ROC-AUC | Gini   | KS     | PR-AUC |
|---------------------|---------|--------|--------|--------|
| Logistic Regression | 0.8597  | 0.7193 | 0.5687 | 0.3810 |
| CatBoost Classifier | 0.8724  | 0.7448 | 0.5922 | 0.4096 |
| Delta PP            | 1.2736  | 2.5372 | 2.4387 | 2.5946 |



**Таким образом:**

**Logistic Regression:**


1. Высокая интерпретируемость.
2. Низкая вычислительная сложность.
3. Хорошее качество risk ranking, умеренно уступающее CatBoost по рассматриваемым метрикам.

**CatBoostClassifier:**

1. Более низкая интерпретируемость.
2. Более высокая вычислительная сложность, которая для текущего объёма данных не является существенным ограничением.
3. Более высокое качество по всем рассматриваемым ranking metrics на final holdout.

Для последующего ранжирования портфеля выбран CatBoost, поскольку на final holdout он показывает более высокое качество дискриминации по всем рассматриваемым метрикам. Logistic Regression при этом сохраняется как интерпретируемый baseline для сопоставления и анализа основных risk drivers.

## Интерпретация модели логистической регрессии



Для интерпретации направления эффектов:


При прочих равных положительные коэффициенты Logistic Regression связаны с более высоким predicted risk, а отрицательные — с более низким predicted risk. Величина коэффициента отражает изменение log-odds положительного класса и не должна интерпретироваться как прямое изменение вероятности серьёзной просрочки или как причинный эффект признака.

**Направления крупнейших коэффициентов в целом согласуются с risk patterns, выявленными в предыдущем анализе:**

1. Сегменты с высоким revolving\_utilization и наличием previous DPD имеют крупные положительные коэффициенты и связаны с повышенным predicted risk.
2. Сегменты молодого и среднего возраста, а также высокого и экстремального debt\_ratio также характеризуются положительными коэффициентами и связаны с повышенным predicted risk.
3. Сегменты с отсутствием previous DPD и низким revolving\_utilization имеют крупные отрицательные коэффициенты и связаны с пониженным predicted risk.
4. Для остальных сегментов абсолютные значения коэффициентов преимущественно ниже, поэтому их вклад в linear predictor выражен слабее.

Направления крупнейших коэффициентов Logistic Regression в целом согласуются с risk patterns, выявленными в предыдущем анализе. Это служит дополнительным sanity check содержательной согласованности модели, но не является доказательством причинной связи между признаками и риском серьёзной просрочки.

## Проверка risk ranking: predicted risk vs observed bad rate



Observed bad rate монотонно возрастает от низких risk deciles к высоким: с 0,33% в D1 до 37,13% в D10. Это подтверждает, что на final holdout модель эффективно ранжирует заёмщиков по уровню относительного риска. При этом predicted risk scores систематически превышают observed bad rate, поэтому выход модели следует интерпретировать как risk score для ранжирования, а не как откалиброванную probability of default.